


AI Test Edilebilir mi?

Doğru cevabın ne olduğunu bilmediğimizde
test mühendisi ne yapar?



oracle problemi - test seviyeleri - klasik tekniklerin AI karşılığı

Kasım Deliaçı
Bursa Teknik Üniversitesi - Bilgisayar Mühendisliği
21360859021

Bugün ne konuşacağız?

01

Klasik test varsayımı

Beklenen sonuç, expected result ve oracle

02

AI bu tabloyu nasıl değiştirir?

Veri, model, metrikler ve test seviyeleri

03

Klasik tekniklerin AI karşılığı

Metamorphic, back-to-back, A/B, regression

04

Risk ve rol değişimi

Güvenlik, sorumluluk ve test mühendisinin yeni odağı

AI eval vs AI Testi

AI testi yeni bir disiplin gibi görünür; ama çoğu mesele tanıdık kavramların yeni bir zemine taşınmasıdır.

oracle

test basis

**test
levels**

regression

back-to-back


Odak AI aracı değil; test mühendisliği kavramlarının AI sistemlerinde nasıl çalıştığı.

Testin gizli varsayımı

Test yazarken farkında olmadan hep şunu varsayarız: doğru cevabı zaten biliyoruz.

NEDEN ÖNEMLİ

Bu varsayım çoğu zaman doğrudur: bir login denemesinin sonucunu ya da boş bir formun ne hata vereceğini önceden biliriz. Sorun, bu “doğru cevabı bilme” lüksünün her zaman olmamasıdır.




gelen sonuç == beklediğimiz sonuç

Oracle: testin hakemi

ORACLE PROBLEMİ NEDİR

“Oracle” testin hakemidir: bir çıktının doğru mu yanlış mı olduğunu söyleyen şey. Klasik testte beklenen sonuç bu hakemdir. Hakemin olmadığı ya da çok pahalı olduğu duruma “oracle problemi” denir (Weyuker, 1982).



Hakem yoksa, testin geçip geçmediğini söylemek de zorlaşır.

Doğru cevap bazen yoktur

Ama bazı sistemlerde “tek doğru cevap” diye bir şey yoktur. Zor olan sonucun doğru olduğuna nasıl karar vereceğimiz.

Arama sıralaması

En iyi sonuç hangisi?

BÖYLE DURUMLARDA

Klasik “beklenen sonuçla karşılaştır” yöntemi tıkanır.

Öneri sistemi

Tek doğru liste yok

İklim simülasyonu

Gerçek sonucu beklemek pahalı

LLM özeti

Birden fazla iyi özet olabilir

Weyuker’in “test edilemeyen program” tartışması burada başlar; ISO/IEC 29119-11 bunu AI testinin ana zorluğu olarak görür.



AI bu varsayımı neden kırıyor?

Davranış artık sadece koddan değil; veriden, modelden ve ortamdan doğar.

Geleneksel yazılım	AI / ML sistemi
Kuralı mühendis yazar	Davranış veriden öğrenilir
Aynı girdi, aynı çıktı	Çıktı her seferinde değişebilir
Beklenen sonuç daha nettir	Metrik ve eşik gerekir
Hata çoğunlukla kodda aranır	Hata veri, model, pipeline veya ortamda olabilir

V-model bozulmaz, genişler

CT-AI klasik test seviyelerini korur; AI için iki özel seviye ekler.




**CT-AI klasik component / integration / system / acceptance seviyelerini atmaz;
önüne veri ve model testini ekler.**

ML'de kabul kriteri metrik olur

Accuracy, precision, recall ve F1 gibi metrikler test kararının parçası haline gelir.

Kabul kriteri artık sadece metinsel bir beklenti değil; sayısal eşikler de test kararının parçasıdır.



LLM bunu görünür hale getirir

Açık uçlu cevaplar exact match testini zayıflatır; ama problem LLM'den ibaret değildir.

Açık uçlu

tek doğru cevap yok

Değişken

aynı prompt farklı cevap

Akıcı

akıcı olması doğru
olduğu anlamına gelmez

Hassas

küçük ifade farkı sonucu
etkiler

LLM bu problemi büyütür; ama temel mesele hâlâ oracle ve kabul kriteridir.

Yanlış çıktı gerçek risk üretir


Air Canada'nın chatbot'u geçerli olmayan bir indirim uydurdu ve mahkeme şirketi sorumlu tuttu.

BBC

Airline held liable for its chatbot giving passenger bad advice - what this means for travellers

Yanlış çıktı

chatbot yanlış indirim bilgisi verdi



Sorumluluk

kullanıcı kararı etkilendi; şirket sorumlu tutuldu

AI hatası sadece teknik hata değil; ürün, güven ve hukuk riskidir.

Yeni soru: kabul edilebilir mi?


Artık tek doğru cevabı aramıyoruz; davranışın kabul edilebilir sınırdaki kalıp kalmadığına bakıyoruz. Sistem güvenli mi, tutarlı mı gibi sorular soruyor, test kesin eşitlikten ziyade davranış sınırlarına kayıyor.

Eski soru

çıktı beklenene eşit mi?

Yeni soru

davranış kabul edilebilir sınırdaki mi?




Metamorphic testing

Doğru cevabı bilmesek bile, korunması gereken ilişkiyi test edebiliriz.

Metamorphic = oracle yerine geçen ilişki.

`classify(rotate(img)) == classify(img)`



Örnek: görüntü biraz döndüğünde sınıflandırma tamamen değişmemeli.

İlişki oracle olabilir


Beklenen değer yerine, beklenen davranış ilişkisini kullanırız.

Görüntü	küçük rotasyon	→	sınıf değişmemeli
Arama	filtre ekle	→	sonuç sayısı artmamalı
LLM	soruyu yeniden yaz	→	cevap çelişmemeli
Özetleme	küçük yazım hatası	→	ana anlam korunmalı

Golden dataset yeni bir fikir değil


Test mühendisliği diliyle: frozen test basis + regression testing.

Golden dataset, sistemin doğruya yakın davranmasını beklediğimiz, önceden seçilmiş ve genellikle uzman tarafından onaylanmış örnek veri setidir.



Back-to-back testing

Endüstride differential testing denir; ISTQB'nin resmi terimi back-to-back testing.



A/B testing ile karıştırmayalım

A/B daha iyi varyantı seçer; back-to-back hata sinyalini arar.

A/B testing

hangi varyant daha iyi?
istatistiksel performans karşılaştırması


Back-to-back

çıktılar neden farklı?
defect sinyali arama

Biri iyileştirme ölçer; diğeri hata sinyali arar.

Hakem de AI olursa?

LLM-as-a-judge, pseudo-oracle fikrinin GenAI karşılığı gibi düşünülebilir.



Kullanışlıdır ama tarafsız değildir: uzun cevap, sıralama etkisi ve model yanlılığı görülebilir.

Güvenlik de test kapsamıdır

Prompt injection, veri sızıntısı ve adversarial davranışlar kalite riskidir.

prompt injection

data leakage

data poisoning

adversarial attacks



Test mühendisi neye dönüşür?

Rol kaybolmaz; veri, model ve risk okuryazarlığıyla genişler.

Eski ağırlık

expected output
test case
pass/fail



Yeni ağırlık

data literacy
model behaviour
risk-based testing
oracle strategy
production monitoring

AI testi yeni bir dünya değil.

Test mühendisliğinin oturmuş kavramları

oracle, test temeli, test seviyeleri, regresyon ve back-to-back

veriden öğrenen sistemlere uygulanır.

Kaynakça

1. ISTQB CT-AI Syllabus v2.0, 2026/04/17. istqb.org/wp-content/uploads/2026/05/ISTQB-CTAI_Syllabus_v2.0_Release.pdf
2. ISTQB CT-AI Syllabus v1.0, 2021. istqb.org/wp-content/uploads/2024/11/ISTQB_CT-AI_Syllabus_v1.0_mghocmT.pdf
3. ISO/IEC TR 29119-11:2020. Software testing - Guidelines on testing AI-based systems. iso.org/standard/79016.html
4. ISTQB Glossary. glossary.istqb.org
5. Weyuker, E. J. (1982). On Testing Non-Testable Programs. The Computer Journal 25(4):465-470. DOI: 10.1093/comjnl/25.4.465
6. Chen, T. Y., Cheung, S. C., & Yiu, S. M. (1998). Metamorphic Testing: A New Approach for Generating Next Test Cases.
7. Barr et al. (2015). The Oracle Problem in Software Testing: A Survey. IEEE TSE 41(5):507-525.
8. NIST AI Risk Management Framework 1.0; NIST Generative AI Profile. nist.gov
9. OWASP Top 10 for LLM Applications. owasp.org/www-project-top-10-for-large-language-model-applications/
10. Zheng et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. arxiv.org/abs/2306.05685
11. National Magazine. Air Canada chatbot case. nationalmagazine.ca